



당근 ML Infrastructure (GCP)

☼ 상태	완료
☰ 다중 선택	Training Pipeline

ML Infrastructure with GCP | 2025 당근 GCP 밋업

ML Infrastructure with GCP | 2025 당근 GCP 밋업

당근마켓은 GCP를 왜, 어떻게 사용하고 있을까요? 인프라 관점에서 GCP를 활용해 본 당근의 이야기를 들려드립니다.

<https://www.youtube.com/watch?v=CfAUzt0zIFM>

당근 인프라의 GCP 활용법

ML Infrastructure with GCP



박준선 | 당근 ML 인프라 팀

당근의 학습 파이프라인 요소 결정

1. 쿠버네티스의 kubeflow : 학습 파이프라인 orchestration

Training Pipeline - Kubeflow

Kubeflow Pipelines

- ML Pipeline Orchestrator based on Argo Workflow
- Provides **extensibility and flexibility with Python**
- Run workflows through **reusable components**
- Supports TensorFlow, PyTorch, XGBoost, Etc



- 장점
 - ML 구성하는 component 재사용 가능
 - 파이썬 기반으로 컴포넌트 확장 가능
 - 단점 : 자유도가 높아서
 - 규칙 X
 - 예상치 못한 문제
2. TFX에서 제공하는 컴포넌트 활용


Training Pipeline - TFX

Kubeflow Pipelines

- ML Pipeline Orchestrator based on Argo Workflow
- Provides extensibility and flexibility with Python
- Run workflows through reusable components
- Supports **TensorFlow**, PyTorch, XGBoost, Etc


TFX(TensorFlow eXtended)

- End-to-end platform for ML pipelines
- Provides a **comprehensive set of components and libraries** to handle **various stages of an ML workflow**
- Supports **ML metadata** for **Kubeflow** and **Apache Beam** for distributed data processing and scalable workloads



- 효과
 - 파이썬 활용
 - 검증된 구조와 인터페이스 바탕으로 파이썬 파이프라인을 작성
 - ⇒ 코드 일관성, 재사용성 높음, 디버깅 범위도 예측 가능한 영역 안으로 제한되었음
 - 구글 프레임 워크
 - ⇒ 대규모 연산에 특화
 - ⇒ Dataflow와 TFX 연동 쉬움

Training Pipeline - TFX



Data Processing 단계

1. BigQuery 에서
2. SQL로 데이터를 읽어온 뒤
3. 검증하고
4. 학습에 활용하기 좋은 형태로 Transform 과정을 거쳐 변형

• 환경에 따른 파이프라인 실행 차이:

- **실험 환경:** 다양한 피쳐(Feature)와 데이터를 테스트해야 하므로, **데이터 프로세싱과 모델 학습이 하나의 시퀀스로 함께 실행됨**
- **프로덕션 환경 (또는 피쳐 플랫폼):** 미리 가공된 데이터를 여러 파이프라인이 재사용하므로, 프로세싱을 건너뛰고 **바로 다음 단계(초록색 부분)부터 시작하기도 함**

- 현재 이미지의 흐름 = 실험 환경 (또는 기본 파이프라인):

- 파란색 단계(`BigQuery Data Ingestion` → `ExampleGen` → `Transform`)를 거쳐 초록색 단계(`Trainer`)로 화살표가 하나로 쭉 이어진다
- 데이터를 매번 새로 추출하고 가공해서 학습까지 한 번에 돌려보는 **실험 환경**의 흐름을 그대로 보여주는 형태

- 만약 피쳐 플랫폼이 반영된 이미지였다면?:

파란색(Data Processing)과 초록색(Model Training) 사이에 [Feature Store (피쳐 플랫폼)]이라는 별도의 블록이 있었을 것입니다. 그리고 복잡한 파란색 단계를 거치지 않고, 피쳐 플랫폼에서 바로 초록색의 `Trainer` 컴포넌트로 데이터가 꽂히는 화살표가 추가로 그려져 있었을 것입니다.

Model Training 단계

프로세싱을 거쳐 준비된 데이터를 바탕으로 실제 모델을 '학습'시키는 단계

- 주기적으로 동작하는 프로덕션 파이프라인의 경우, 데이터 준비 시간을 단축하기 위해 이 단계부터 파이프라인이 시작되는 경우가 많음

Model Storage & Serving 단계

- **모델 저장:** 학습이 완료된 모델을 클라우드 스토리지 (GCP의 GCS, AWS의 S3 등)에 업로드
- **모델 서빙:** 서버를 재시작하여 새롭게 학습된 모델을 실제 서비스 환경에 반영(Serving)